مجموعة بيانات سيول جدة — كيف بُنيت

سؤال المشروع: كيف يتعرّض بلد شحيح المياه لسيول مدمّرة؟

سؤال البيانات: أيّ الأماكن في جدة معرّضة لتجمّع مياه السيول، ولماذا؟ وهو سؤال عن **المكان**.

ما هي هذه البيانات؟

قسّمنا منطقة جدة إلى مربعات صغيرة، كل مربع **30 م × 30 م**، وأخذنا عيّنة منها في عاصفتين: **21 نوفمبر 2017** و**24 نوفمبر 2022**.

الصف الواحد = مربع واحد في عاصفة واحدة. لكل صف معلومات عن المكان والطقس، و«إجابة»:

- **1** = رأى القمر الصناعي (الرادار) ماء سيل جديدًا في المربع بعد العاصفة بأيام.
- **0** = رآه الرادار جافًّا. وهذا **لا يعني «آمن»**، بل «جاف في ذلك اليوم» فقط.

المربع نفسه قد يظهر مرتين (مرة لكل عاصفة)، والعمود الذي يحدد العاصفة هو:

`event_id`

المصادر الخمسة وما يضيفه كل منها

المصدر	ماذا يضيف
رادار رص nel-1)	
نموذج ا GLO-30	
خريطة r 2021	
أقمار ال RG V07	
قمر رط MAP L4	
مصدر س مجانية وه	

One row of the dataset = one 30 m × 30 m cell in one storm

A real row from jeddah_flood_ml (selected columns)

Identity	
cell_id	2448889
event_id	JED_20171121
lon, lat	39.1223°E, 21.3040°N
block_id (1 km)	512_2355
t0_utc (storm start)	2017-11-21T00:00:00Z

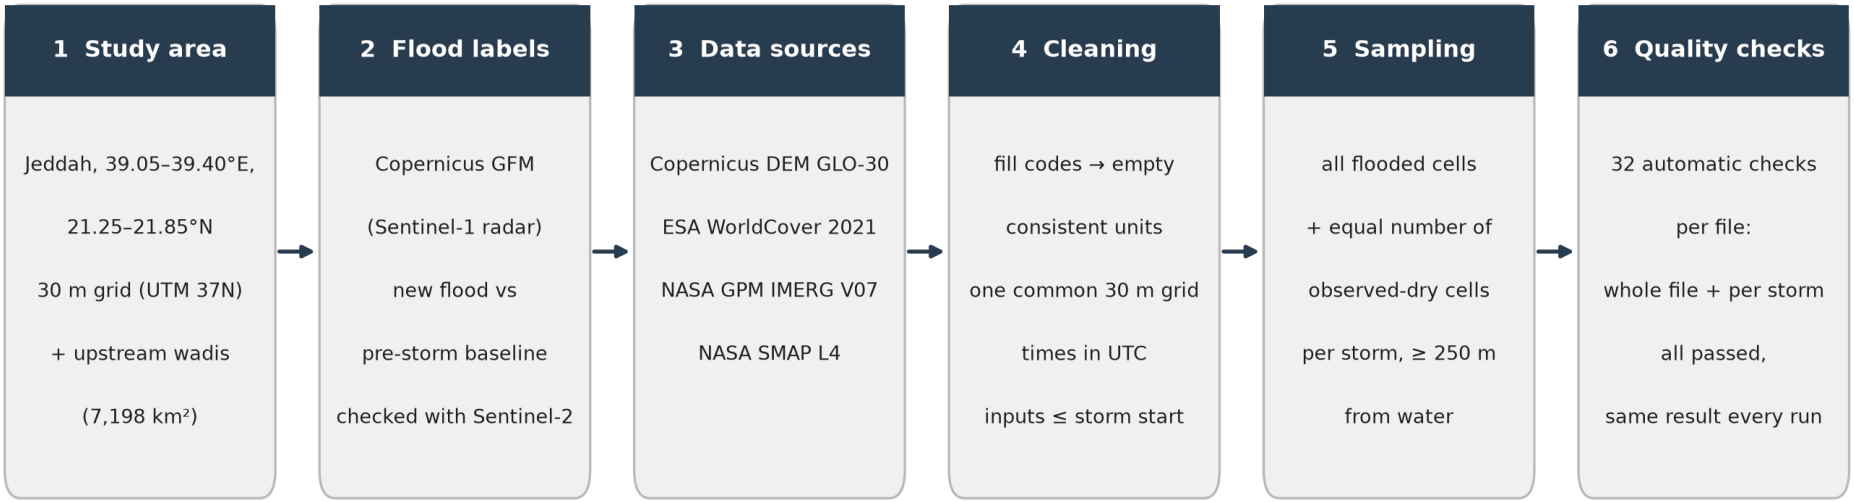
Place (static, before the storm)	
elevation_m	-0.16 m
slope_deg	0.17°
flowacc_km2	0.0441 km²
twi	13.12
hand_m	0.00 m
landcover_name	bare_sparse
dist_to_coast_m	1,612 m
dist_to_ref_water_m	1,274 m

Weather (this storm)	
rain_event_24h_mm	20.0 mm
rain_event_max30_mmhr	9.1 mm/h
rain_antecedent_7d_mm	0.00 mm
sm_surface_m3m3	0.045 m³/m³

Answer and quality (never model inputs)	
label	1 (flooded)
flood_fraction	1.00
label_obs_utc	2017-11-25T15:28:43Z
s2_water_confirmed	1 (Sentinel-2 sees water)

صف حقيقي من الملف (مربع عُمر في 2017 وفي 2022، وأكّدت Sentinel-2 وجود الماء فيه).

How the dataset was built



خطوات بناء البيانات الست: منطقة الدراسة ← إجابات الفيضان ← أربعة مصادر ← التنظيف ← اختيار العيّنة ← فحوص الجودة.

كيف صُنعت الإجابات وتم التحقق منها

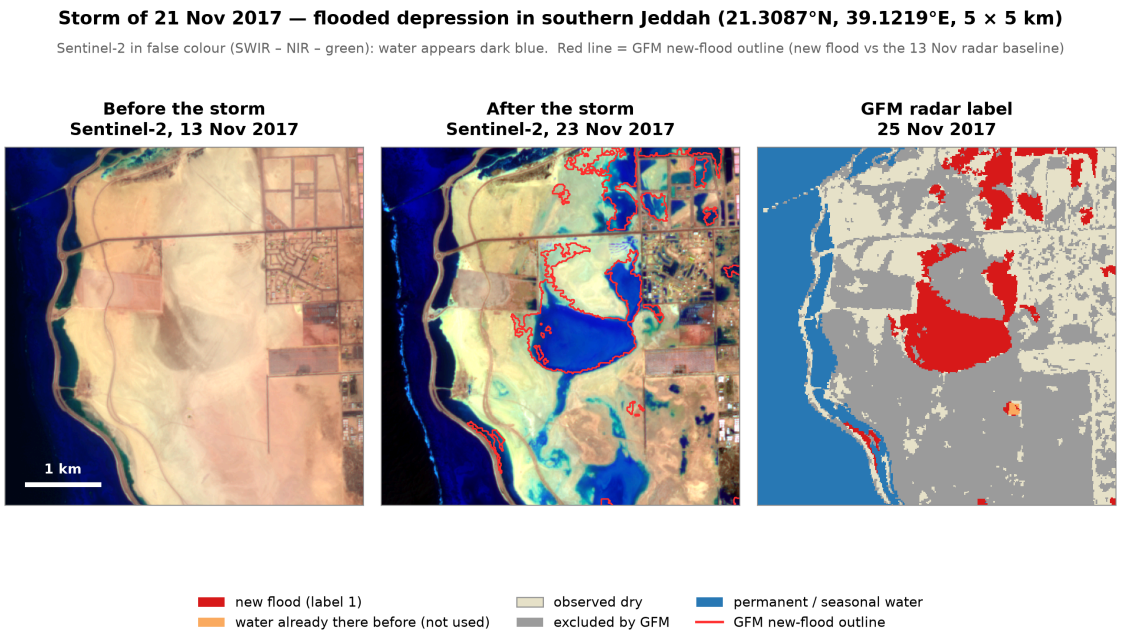
الإجابة من الرادار

- الإجابة من منتج الرصد العالمي للفيضانات Copernicus GFM وهو مبني على رادار Sentinel-1 الذي يرى عبر الغيوم.
- **صورة بعد العاصفة بأيام** (25 نوفمبر 2017، و29 نوفمبر 2022) تُقارن بـ**صورة قبلها** من المدار نفسه (13 نوفمبر 2017، و17 نوفمبر 2022).
- **«سيل جديد» فقط:** الماء الموجود أصلًا قبل العاصفة لا يُحسب سيلًا (لا 1 ولا 0). في 2017 استُبعد بذلك 1,248 بكسل، ولم تُظهر Sentinel-2 ماءً في أيٍّ منها (0%).
- **التحقق بالصور الملوّنة** Sentinel-2: رأت ماءً في 55.7% من بكسلات السيل الجديد في 2017 مقابل 0.64% فقط من البكسلات الجافة، وفي 2022: 42.6% مقابل 4.6%.

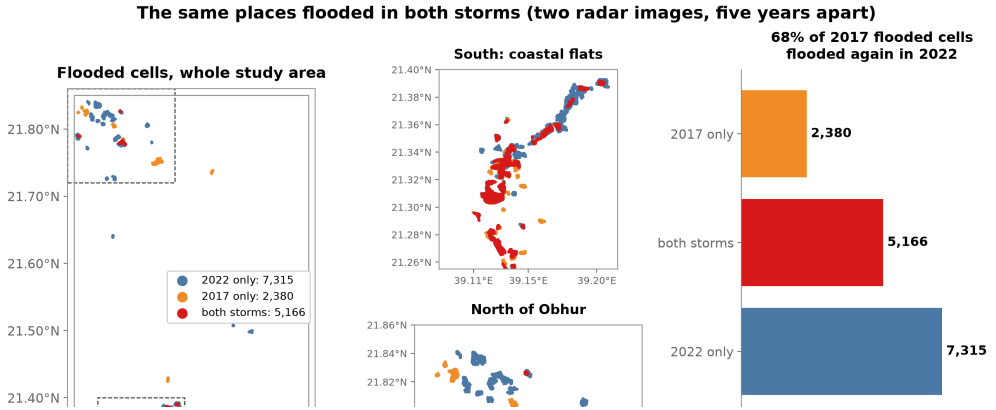
لماذا عاصفتا 2017 و2022 فقط؟

فحصنا كل سيول جدة منذ 2009، وأبقينا فقط العواصف التي لها صورة رادار نظيفة بعد المطر بأيام قليلة.

العاصفة	سبب الاستبعاد
ديسمبر 2025	إشارة لا تتميّز عن الضجيج: 4,360 بكسل «جديد» بين صورتين جافتين مقابل 17,258 بعد العاصفة، وتوافق Sentinel-2 4.9% فقط مقابل 1.8% للجاف.
يناير 2025	أقرب صورة رادار بعد 11 يومًا، فيكون الماء قد انصرف.
يناير 2023	صورة «ما قبل» ما زالت مغمورة بمياه 2022، ولم يظهر جديد يُذكر.
نوفمبر 2015	لا توجد صورة رادار فوق المنطقة.
2009 و2011	قبل القمر Sentinel-1، ولا يوجد مصدر إجابات مماثل.



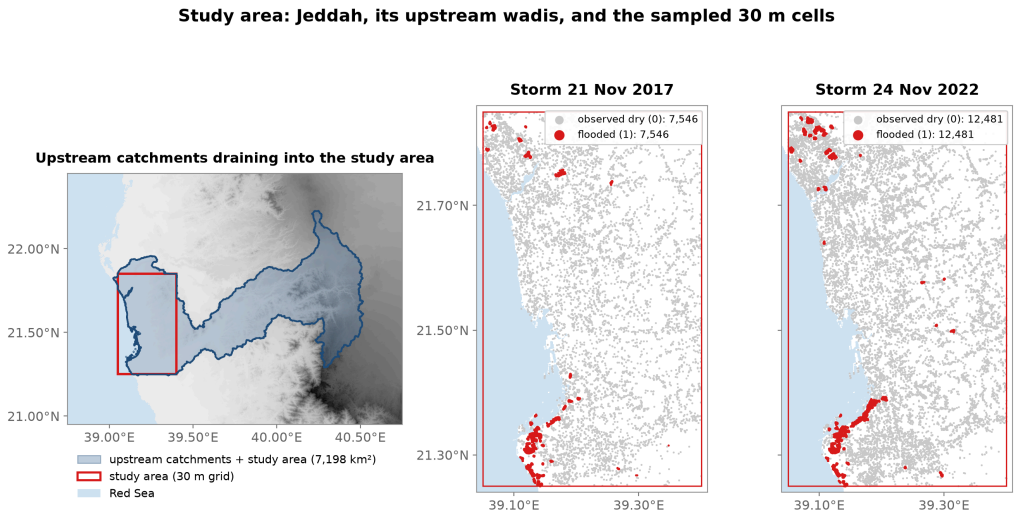
منخفض جنوب جدة في عاصفة 2017: جاف قبل العاصفة، ومغمور بعدها، ويطابق حدود الرادار (الخط الأحمر).

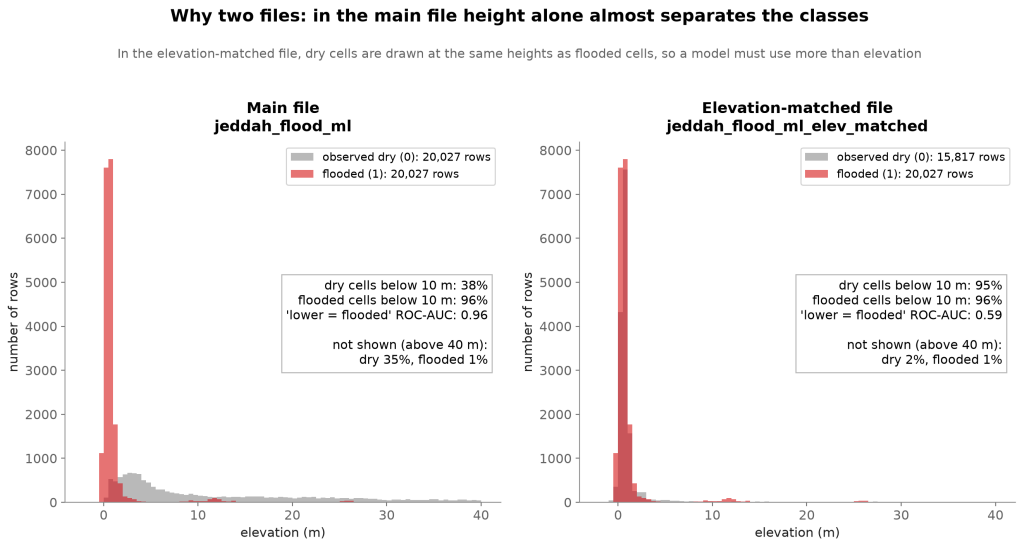


القرارات الرئيسية (وسبب كل منها في سطر)

- **مربع «مغمور» إذا كان 50% منه على الأقل سيلًا جديدًا:** لتجنّب المربعات المغمورة جزئيًّا.
- **الجاف يبعد 250 م على الأقل عن أي ماء:** حتى لا يُعدّ جافًّا ما هو على حافة السيل.
- **عدد الجاف = عدد المغمور في كل عاصفة (1 : 1):** صنفان متوازنان للتعلّم.
- **استبعاد ما يحجبه الرادار صراحة:** المنتج يرمز للمناطق المستبعدة بصفر، فلو لم نستبعدها لصارت «جافة» خطأً.
- **كل المدخلات قبل بدء العاصفة (UTC 00:00):** لا معلومة من المستقبل، والمطر يُستخدم كمُسبِّب فقط.
- **مطر IMERG النهائي (Final) للعاصفتين:** أدق نسخة متاحة.

الملفان، والأرقام، ونتائج الفحص





لماذا ملفان؟ في الملف الرئيسي يكاد الارتفاع وحده يفصل بين الصنفين (96% من المغمور تحت 10 م مقابل 38% من الجاف)، فقد «ينجح» النموذج بتعلّم «المنخفض = مغمور» فقط. في الملف الثاني اختيرت المربعات الجافة على الارتفاعات نفسها، فيُجبر النموذج على استخدام عوامل أخرى.

الملف	2017	2022	المجموع
الرئيسي `jeddah_flood_ml`	15,092 7,546 / 7,546	24,962 12,481 / 12,481	**40,054**
المطابق للارتفاع `jeddah_flood_ml_elev_matched`	13,849 7,546 / 6,303	21,995 12,481 / 9,514	**35,844**

في كل خانة: عدد الصفوف، ثم المغمور / الجاف. منطقة الدراسة مع الأودية التي تصب فيها: 7,198 كم².

نتائج الفحص السريع بكلمات بسيطة

- **البيانات سليمة:** 32 فحصًا آليًّا لكل ملف نجحت كلها، ولا تكرار ولا قيم غير منطقية، ولا عمود محظور يصل إلى النموذج.
- **الارتفاع وحده قوي جدًّا:** «المنخفض = مغمور» يعطي 0.961، والنموذج (غابة عشوائية) 0.978 على أماكن لم يرها.
- **النموذج يتعلّم أكثر من الارتفاع، لكن باعتدال:** في الملف المطابق للارتفاع يهبط الارتفاع وحده إلى 0.586، ويحقق النموذج 0.867، معتمدًا أساسًا على القرب من الساحل.
- **على مناطق أبعد** (كتل 5 و10 كم) ينخفض إلى 0.722 و0.668، لكنه يبقى أعلى من الارتفاع وحده (0.519 و0.480).
- **تحذير:** التقسيم العشوائي يضخّم النتيجة (0.995)، فلا يُستخدم.

أهم القيود

- **الرادار لا يرى داخل المدينة الكثيفة:** نحو ثلثي المنطقة المرصودة مستبعد، فالإجابات تصف ماءً بقي في الأرض المفتوحة لا الشوارع.
- **الصورة بعد 4–5 أيام:** نرى ما تبقّى من الماء، لا ذروة السيل.
- **دقة الارتفاع بضعة أمتار**، بينما نصف المربعات المغمورة تقريبًا تحت 0.6 م.
- **المطر خشن (نحو 11 كم)** ويرتبط بالموقع صدفة، فيُستخدم بحذر.
- **خريطة الغطاء الأرضي من 2021** ولا تعكس هدم الأحياء في 2021–2023.
- **عاصفتان فقط**، والمغمور في تجمّعات ساحلية قليلة، وخانة التحقق بـ Sentinel-2 فارغة في شمال المدينة لـ 2017 بسبب الغيوم.

من أين تبدأ؟

الدليل المبسّط: ماذا في المجلد، وكيف بُنيت البيانات، وكيف تُعاد:

`README.md`

شرح كل عمود، ومن الأعمدة المسموح بها في التدريب:

`data_dictionary.csv`

`use_as_model_input = yes`

الملفات نفسها: